

Cribado fuera de muestra

AlgoProject — manual de uso. Generado el 2026-09-27 con `tools/manual.py`.

1. 1. Análisis IS/OOS — qué métrica del histórico predice el futuro
2. 2. Barrido de filtros — cuánto te da de verdad filtrar, y a cambio de qué
3. 3. Comparar muestras — ¿se cumplen las conclusiones en otra generación?
4. 4. Decaimiento — cuánto del edge sobrevive fuera de muestra, y si te la quedas o no
5. 29. La puerta OOS — de un databank entero a una lista de supervivientes
6. 49. SPA y StepM — ¿bate alguna al buy & hold, pagando toda la búsqueda?

1. Análisis IS/OOS — qué métrica del histórico predice el futuro

Qué pregunta responde

Cuando SQX genera miles de estrategias, todas se ven bien en el periodo con el que se construyeron (**IS**, *in-sample*, el histórico). La pregunta es cuáles siguen viéndose bien en el periodo que no vieron nunca (**OOS**, *out-of-sample*, el futuro simulado).

Este análisis coge todas las estrategias de un databank y mide, métrica por métrica, **cuánta información sobre el OOS hay en el IS**. Si el Sharpe del histórico no dice nada del futuro, filtrar por Sharpe al generar es tirar el tiempo. Si dice algo, dice cuánto.

Cuándo lo usas, y cuándo no

Lo usas cuando tienes un databank grande de estrategias generadas y quieres decidir con qué criterio filtrarlas — o con qué criterio configurar la generación en SQX para el siguiente activo.

No lo usas si las estrategias del databank ya fueron seleccionadas por su resultado OOS. Ahí el análisis mide tu propia selección, no la realidad, y sale un resultado bonito y falso. Necesita estrategias generadas **al azar** y sin filtrar por el resultado que estás estudiando.

Tampoco sirve para elegir una estrategia concreta. Habla de la población entera.

Antes de empezar

Necesitas dos cosas:

1. **Un databank con estrategias** en el proyecto de SQX, retestado, con periodo IS y OOS. Las columnas son las de tu vista `Export Data View`, pero ya no se exportan a través de SQX: se leen del `SQStats` de cada `.sqx` (comprobado igual a la exportación de la vista). No hace falta que ningún SQX esté abierto ni cerrado.

Cómo se ejecuta

Son dos comandos. El primero saca los datos de SQX; el segundo los analiza.

```
cd ~/Desktop/AlgoProject

# 1. refrescar el CSV (medio segundo por cada 100 estrategias: se lee de los .sqx)
python3 -m sqx.export.export_metrics --project XAUUSD --databank 00S

# 2. analizar y generar el reporte (~1 segundo, no toca SQX)
python3 -m studies.screening.is0os.report --project XAUUSD --databank 00S
```

El paso 1 solo cuando quieras datos nuevos. El paso 2 lo puedes repetir las veces que quieras.

export_metrics.py

flag	obligatorio	qué hace
--project	sí	nombre del proyecto tal y como aparece en SQX. Sin espacios: guiones bajos
--databank	sí	nombre del databank, p. ej. 00S
--role	no	conductor o custodian si el proyecto vive en un worker; sin él, el maestro

⚠ **Borra la exportación anterior de ese databank antes de escribir la nueva.** A propósito: así solo hay un CSV y nunca te preguntas cuál es el bueno. Lo que sí se conserva son los reportes.

is_oos.py

flag	obligatorio	qué hace
--project	sí	el mismo proyecto del paso 1
--databank	sí	el mismo databank del paso 1

No toca SQX. Solo lee el CSV que dejó el paso 1.

Qué produce


```
~/Desktop/AlgoData/reports/XAUUSD/00S/2026-09-04/is0os/  
  explorer.html    el panel interactivo. Lo abres con doble clic  
  is0os.html      las conclusiones, la misma página que pinta la ventana  
  is0os.md        las conclusiones escritas, en texto  
  is0os.json      el resultado entero, en el contrato de estudios  
  manifest.json   de qué exportación salió y de qué fecha
```

Hasta el 25-09 estos archivos caían sueltos en la carpeta del día y el texto se llamaba `summary.md` ; ahora cada estudio tiene su subcarpeta (ver `docs/MAPA-DE-CARPETAS.md`).


Una carpeta por día. Los reportes viejos no se borran nunca.

```
xdg-open ~/Desktop/AlgoData/reports/XAUUSD/00S/2026-09-04/is0os/explorer.html
```

Cómo se lee el panel



Anatomía de un gráfico



	qué es
1	la métrica del IS que va en el eje X. La del eje Y es la que elegiste arriba, igual en todos
2	la fuerza de la relación. p (rho) es la que manda; va de -1 a +1 y 0 significa que no hay relación . r es lo mismo calculado de otra forma: si las dos se parecen, fíate; si no, hay valores extremos distorsionando. p es la probabilidad de ver esto por pura casualidad — cuanto más pequeño, mejor
3	cada punto es una estrategia
4	la línea de tendencia. Si sube, más de esa métrica en el IS va con mejor resultado OOS
5	el histograma: dónde están de verdad las estrategias . Aquí casi todas están amontonadas a la izquierda, así que esa línea de tendencia la está estirando un puñado de puntos de la derecha. Sin el histograma no lo verías
6	los extremos del eje


Un **p de 0,2** es una relación real pero floja. Mueve las probabilidades, no decide el resultado. No esperes 0,8: en este negocio no existe.

Los controles

control	qué hace
Eje Y	cambia la métrica de resultado OOS que estás intentando predecir
Puntos dibujados por gráfico	cuántos puntos se dibujan , por defecto 100. Dibujar 10.000 puntos tapa el gráfico entero. Los números no cambian : ρ , la línea y el histograma siempre usan todas las estrategias. Esto solo afecta a lo que ves
Rango de los ejes	por defecto recorta el 1% de cada extremo, porque cuatro estrategias absurdas te aplastan el gráfico. completo enseña todo
Otra muestra	otros 100 puntos al azar, por si te ha tocado una muestra rara

Filtrar


Aquí es donde el panel deja de describir y empieza a servir para decidir. **+ añadir condición** añade una regla: por ejemplo *quédate solo con el 20% de mejor Sharpe en el IS*. Las opciones **% mejores** y **% peores** cortan por percentil; **>**, **≥**, **<** y **≤** cortan por un valor que escribes tú.



En el ejemplo de arriba: filtrando por el 20% de mejor Sharpe IS sobreviven 2.034 estrategias y la mediana del Profit factor OOS sube de 0,950 a 0,990.

El mapa de correlaciones

Debajo de los gráficos hay una tabla de colores que cruza **todas** las métricas del IS (filas) contra todas las del OOS (columnas). Es la vista de pájaro: dónde hay relación y dónde no, sin ir métrica por métrica.



- **Rojo** = relación positiva (más de esa métrica IS va con más resultado OOS). **Azul** = negativa. **Casi blanco** = nada.
- La escala tiene **20 escalones**, y sus extremos son los que marca la leyenda — no −1 y +1. A escala completa todo saldría del mismo color, porque estas correlaciones viven dentro de ±0,3.

- **El puntito blanco** en una casilla significa que ese cruce aguanta la corrección Benjamini- Hochberg dentro de su columna. Con 10.000 estrategias sobrevive casi todo; en cuanto pones un filtro y bajan los supervivientes, los puntos empiezan a desaparecer. Ahí es donde la marca dice algo.
- **Pasa el ratón** por una casilla para ver ρ , r y p exactos; **haz clic** y esa métrica OOS se va al eje Y de los gráficos de arriba.
- Se recalcula con el filtro puesto, igual que todo lo demás.

La tabla de estrategias

Más abajo están las cifras exactas, una fila por estrategia de las que pasan el filtro.

Tabla de estrategias

Las cifras exactas de las estrategias que pasan el filtro. Haz clic en una cabecera para ordenar por esa métrica.

FILAS MOSTRADAS

ORDENAR POR

SENTIDO

100

Profit factor (OOS)

de mayor a menor

100 de 10.000 estrategias que pasan el filtro

Estrategia	# of trades (IS)	CAGR/Max DD % (IS)	CalmarRatio (IS)	DoF Ratio (IS)	Drawdown (IS)	Max DD % (IS)	Net profit (IS)	PSR (IS)	Param Count (IS)	Profit factor (IS)	R Expectancy (IS)
Strategy 10.16.36	103	-0.060	-0.060	10.30	5517	5.42	-3483	0.170	10.00	0.770	-0.130
Strategy 18.2.23	123	0.050	0.050	8.20	4114	3.95	1978	0.660	15.00	1.12	0.060
Strategy 15.14.31	107	0.160	0.160	10.70	3372	3.12	5161	0.810	10.00	1.28	0.140
Strategy 10.15.43	103	-0.060	-0.060	10.30	5989	5.86	-3365	0.180	10.00	0.780	-0.130
Strategy 10.20.32	104	0.130	0.130	8.67	3181	2.97	3832	0.820	12.00	1.31	0.150
Strategy 6.17.24	121	0.320	0.320	11.00	3265	2.93	9798	0.960	11.00	1.58	0.270
Strategy 23.6.43	199	0.070	0.070	19.90	6665	6.38	4626	0.800	10.00	1.18	0.090
Strategy 16.21.26	107	0.180	0.180	8.23	1990	1.97	3566	0.900	13.00	1.36	0.180
Strategy 23.6.28	101	0.180	0.180	8.42	3217	3.22	5913	0.830	12.00	1.33	0.160
Strategy 5.11.29	163	0.080	0.080	8.15	4533	4.19	3549	0.730	20.00	1.17	0.090
Strategy 15.10.36	127	0.350	0.350	11.55	2738	2.73	10003	0.970	11.00	1.59	0.260
Strategy 7.9.27	106	0.150	0.150	7.07	2262	2.15	3237	0.830	15.00	1.32	0.150
Strategy 13.9.36	200	0.290	0.290	15.38	4106	3.64	11217	0.950	13.00	1.38	0.170
Strategy 23.9.30	103	0.160	0.160	8.58	3128	3.13	5164	0.800	12.00	1.29	0.130
Strategy 2.9.38(1)	97.00	-0.040	-0.040	6.06	5044	4.94	-1968	0.340	16.00	0.870	-0.070
Strategy 22.8.23	148	0.570	0.570	14.80	3956	3.57	22094	1.00	10.00	2.05	0.460

Ordena haciendo clic en cualquier cabecera, o con los despleables. `filas mostradas` limita cuántas se pintan (100 por defecto) — no cambia el filtro, solo lo que ves. Sirve para lo que un gráfico no sirve: ver quién es exactamente la estrategia que está en esa esquina de la nube.

Al final de la página

Hay cuatro fichas explicando **r de Pearson**, **p de Spearman**, **el p-valor** y **Benjamini-Hochberg**: qué mide cada uno, y sobre todo qué no. Están ahí porque el panel se lo acabas enseñando a alguien, y esas tres cifras no se explican solas.

Cómo se lee `is0os.md`

Es lo mismo en texto, pero calculado sobre las 10.000 y sin poder filtrar. Tiene tres partes:

Persistencia — si cada métrica mantiene su valor del IS al OOS. La columna `00S/IS` por debajo de 1 significa que empeora al salir del histórico, que es lo normal.

Predicción — para cada resultado OOS, el ranking de métricas del IS que lo anticipan.

La columna **BH** — un ✓ significa que ese resultado aguanta la corrección por haber probado muchas métricas a la vez. Sin ✓, ignóralo aunque el número se vea bien: probando 21 métricas, una sale bien por azar.

IS metric	ρ	r	p	BH
Sharpe Ratio (IS)	+0.223	+0.175	2.04e-113	✓
PSR (IS)	+0.220	+0.175	3.14e-110	✓
# of trades (IS)	-0.019	-0.052	0.0519	

Un ejemplo completo

Pregunta: ¿me sirve el Sharpe del histórico para elegir estrategias de oro?

```
cd ~/Desktop/AlgoProject
python3 -m studies.screening.is0os.report --project XAUUSD --databank 00S
```

```
10000 strategies, 21 IS metrics x 13 00S
/home/sergioguslw/Desktop/AlgoData/reports/XAUUSD/00S/2026-09-04/is0os/is0os.html
/home/sergioguslw/Desktop/AlgoData/reports/XAUUSD/00S/2026-09-04/is0os/explorer.html
```

Abres el panel, dejas **Profit factor (00S)** en el eje Y y miras el primer gráfico: **Sharpe Ratio (IS)**, ρ +0.223. Hay señal, pero floja.

Añades el filtro *Sharpe Ratio (IS)* — *top %* — 20. Arriba aparece:

2034 de 10.000 pasan el filtro (**20.3%**) · mediana de Profit factor (OOS): **0.990** filtrado vs 0.950 sin filtrar

Respuesta: **sí, pero poco**. Descartando el 80% de las estrategias, la mediana del profit factor OOS pasa de 0,950 a 0,990 — sigue por debajo de 1. Sirve como un filtro más, no como *el* filtro.

Y algo que solo se ve haciéndolo: **con el filtro puesto, el ρ del propio Sharpe se desploma de +0.223 a +0.088**, y pasa a mandar otra métrica. Dentro del 20% bueno, el Sharpe ya no distingue. Ese es el motivo de que el panel recalcula todo al filtrar en vez de enseñarte siempre los mismos números.

Qué NO te dice

- **No dice que una estrategia sea buena.** Habla de tendencias en miles de estrategias. Una concreta puede estar en cualquier sitio de esa nube.
- **No dice que la métrica cause el resultado.** Dice que van juntas.
- **Solo vale para este activo y este periodo.** Que el Sharpe funcione en XAUUSD no dice nada de los índices. Hay que repetirlo por activo.
- **No te dice si el filtro merece la pena.** Ves que la mediana sube y cuántas estrategias pierdes, pero no si esa subida aguanta o es ruido de haber probado muchos filtros. Para eso está la página 2, *Barrido de filtros*, que prueba 210 candidatos con intervalo de confianza y corrección.
- **No hay costes reales metidos.** Son los números que da SQX con su configuración de comisiones.

Si algo falla

FileNotFoundError: ../metrics/XAUUSD/00S/metrics.csv No has hecho el paso 1 para ese databank, o escribiste otro nombre. Los nombres son los de SQX, con mayúsculas y todo.

El CSV sale con una sola línea El worker exportó antes de terminar de cargar las estrategias. Vuelve a lanzar el paso 1.

explorer.html tarda en abrir Normal: son unos megas porque lleva dentro las 10.000 estrategias, que es lo que le permite recalcular al filtrar sin volver a pedir nada.

El panel se ve en blanco Ábrelo con doble clic o con `xdg-open` . Arrastrarlo a una pestaña también funciona.

2. Barrido de filtros — cuánto te da de verdad filtrar, y a cambio de qué

Qué pregunta responde

El análisis IS/OOS (página 1) te dice **qué métricas del histórico llevan información** sobre el futuro. No te dice qué hacer con ellas. Esta página sí:

"Si me quedo solo con el 10% de mejor CAGR/Max DD del histórico, ¿cuánto mejora el resultado fuera de muestra, cuántas estrategias pierdo, y esa mejora es real o es que he probado muchas combinaciones hasta que una salió bien?"

El comando prueba **210 filtros candidatos** de una tacada — cada métrica IS cortada por arriba y por abajo al 5, 10, 20, 30 y 50% — y de cada uno reporta la mejora, el intervalo de confianza de esa mejora y cuántas estrategias sobreviven.

Cuándo lo usas, y cuándo no

Lo usas para decidir dos cosas concretas: qué condiciones de aceptación poner en la generación de SQX, y con qué criterio cribar un databank antes de pasar al testeo serio.

No lo usas con estrategias que ya fueron seleccionadas por su resultado OOS — igual que la página 1, ahí mides tu propia selección. Tampoco lo uses para elegir *una* estrategia: habla de poblaciones.

Y no lo uses como coartada: que un filtro salga con ✓ no significa que dé dinero. Significa que la mejora que muestra no se explica por el azar del muestreo.

Antes de empezar

Lo mismo que la página 1, y nada más:

1. El CSV de métricas del databank ya exportado (`python3 -m sqx.export.export_metrics --project XAUUSD --databank 00S`).
2. Nada de SQX. Este comando no lo toca: puedes correrlo con la GUI abierta.

Cómo se ejecuta

```
cd ~/Desktop/AlgoProject
python3 -m studies.screening.filters.report --project XAUUSD --databank 00S
```

flag	obligatorio	qué hace
--project	sí	nombre del proyecto tal y como aparece en SQX
--databank	sí	nombre del databank, p. ej. 00S
--target	no	columna OOS a mejorar. Repetible. Por defecto Sharpe Ratio (00S) y Ret/DD Ratio (00S)
--top	no	cuántos filtros lista por resultado. Por defecto 15

Tarda unos 40 segundos con 10.000 estrategias y dos objetivos: casi todo es el bootstrap, que son 2.000 remuestreos por cada filtro candidato.

Qué produce

```
~/Desktop/AlgoData/reports/XAUUSD/00S/2026-09-04/filters/  
  filters.md      la tabla de filtros, en texto (antes `improvement.md`)  
  filters.html    la misma tabla como página  
  filters.json    el resultado entero, en el contrato de estudios  
  manifest.json   de qué CSV salió y con qué versión del código
```

Va en su propia subcarpeta filters/ dentro del reporte del día, para no pisar el manifest.json del análisis IS/OOS. Se sobrescribe si lo repites el mismo día; los días anteriores no se tocan.

Cómo se lee el resultado

```
## Sharpe Ratio (00S)  
  
Unfiltered: 10,000 strategies · median -0.280 · 25.6% above 0.  
108 of the 210 filters judged both improve the median and survive the correction.  
  
| filter | kept | median | Δ median | 95% CI on Δ | hit % | Δ hit pp |  
p | BH |  
| CAGR/Max DD % (IS) top 5% | 511 | -0.020 | +0.260 | [+0.230,+0.300] | 47.7 | +22.2 |  
5.00e-04 | ✓ |  
| Sharpe Ratio (IS) top 5% | 528 | -0.020 | +0.260 | [+0.230,+0.300] | 47.9 | +22.4 |  
5.00e-04 | ✓ |  
| CAGR/Max DD % (IS) top 10% | 1,018 | -0.030 | +0.250 | [+0.230,+0.280] | 46.3 | +20.7 |  
5.00e-04 | ✓ |  
| PSR (IS) top 10% | 1,045 | -0.030 | +0.250 | [+0.220,+0.270] | 45.7 | +20.2 |  
5.00e-04 | ✓ |  
| Profit factor (IS) top 20% | 2,019 | -0.050 | +0.230 | [+0.200,+0.240] | 43.7 | +18.1 |  
5.00e-04 | ✓ |
```

Columna por columna:

columna	qué es
filter	la condición. top 10% = quedarse con el 10% de valor más alto de esa métrica IS; bottom = el más bajo
kept	cuántas estrategias sobreviven. Este es el precio del filtro
median	la mediana del resultado OOS entre las supervivientes
Δ median	cuánto sube esa mediana frente a no filtrar. Es la ganancia
95% CI on Δ	el intervalo de esa ganancia. Si incluye el 0, la mejora no se distingue del ruido — es la columna que decide
hit %	qué porcentaje de las supervivientes acaba por encima del punto de equilibrio (0 para Sharpe y Ret/DD; 1 para profit factor)
Δ hit pp	lo mismo en puntos porcentuales frente a no filtrar. Suele ser la cifra más intuitiva
p	p-valor bootstrap. Tiene suelo en $1/2000 = 5.00e-04$: cuando está pegado ahí, mira el intervalo, no el p
BH	✓ = aguanta la corrección por haber probado 210 filtros a la vez

Lo que hay que mirar primero es **kept** y **Δ hit pp**, en ese orden. Un filtro que sube 20 puntos la tasa de acierto tirando el 90% de las estrategias es una decisión distinta a uno que sube 18 tirando el 80%, y la elección depende de cuántas estrategias necesites al final del embudo.

Un filtro que deja **menos de 200 supervivientes ni se evalúa**. Con 12 estrategias vivas cualquier mejora es un espejismo, y la regla está fijada de antemano para que no se decida caso por caso.

Un ejemplo completo

Pregunta: **¿qué condición de aceptación pongo en la generación de XAUUSD?**

```
cd ~/Desktop/AlgoProject
python3 -m studies.screening.filters.report --project XAUUSD --databank 005
```

```
210 candidate filters over 10000 strategies, 2 outcomes
/home/sergioguslw/Desktop/AlgoData/reports/XAUUSD/005/2026-09-04/filters/filters.md
```

En **filters.md**, para **Ret/DD Ratio (005)**:

Best surviving filter: **Sharpe Ratio (IS) top 5%** — keeps 528 strategies, median 0.015 (+0.485), hit rate 50.4% (+23.7 pp).

Lectura en cristiano: sin filtrar, **el 26,7%** de las estrategias acaba con Ret/DD positivo fuera de muestra. Quedándote con el 5% de mejor Sharpe del histórico, **el 50,4%** — casi el doble de tasa de acierto, a cambio de descartar 19 de cada 20 estrategias generadas.

Dónde deja de pagar apretar más. Esa es la pregunta que contesta tener los cortes 5 y 10 juntos:

corte	sobreviven	acierto OOS
sin filtro	10.000	26,7%
top 10%	~1.020	48,6%
top 5%	~510	50,4%

El primer corte compra **22 puntos**; apretar del 10% al 5% compra **menos de 2 más** y te deja la mitad de estrategias. La curva se aplana: **el 10% es el punto razonable** salvo que necesites lo mejor de lo mejor y te sobren candidatas.

Una segunda cosa que se ve sola en la tabla: `CAGR/Max DD %`, `CalmarRatio`, `R Expectancy`, `SQN`, `Profit factor`, `Sharpe` y `Sortino` al 10% dan **prácticamente el mismo resultado**. No son siete filtros: son siete formas de medir lo mismo. Aplicarlos a la vez no multiplica nada, solo estrecha el embudo.

Qué NO te dice

- **No dice que combinando filtros mejore más.** Solo se barren condiciones sueltas. Dos condiciones a la vez son otro espacio de búsqueda y necesitan otra corrección.
- **No dice que el filtro valga para otro activo.** Todo esto es XAUUSD y este periodo. Hay que repetirlo por activo antes de generalizar nada.
- **No dice nada sobre costes reales.** Son los números de SQX con su configuración de comisiones.
- **No convierte una mejora estadística en dinero.** Sube la proporción de estrategias decentes en lo que sale del generador; lo que hagas después con ellas es otro problema.
- **El intervalo no cubre el riesgo de que el periodo OOS sea atípico.** Cubre el muestreo dentro de estos datos, no que 2023 se parezca a 2026.

Si algo falla

lo que ves	qué pasa
<code>FileNotFoundError:</code> <code>.../metrics.csv</code>	no has exportado ese databank todavía. Corre <code>export_metrics</code> primero
<code>KeyError: 'Sharpe Ratio (OOS)'</code>	la vista de SQX no trae esa columna en OOS. Pásale <code>--target</code> con una que sí exista
tarda varios minutos	normal si el databank es mucho mayor de 10.000 estrategias: el bootstrap crece con el número de supervivientes

3. Comparar muestras — ¿se cumplen las conclusiones en otra generación?

Qué pregunta responde

Las páginas 1 y 2 sacan conclusiones de **una** población: *"filtrando por el 10% de mejor Sharpe IS, la tasa de acierto OOS sube del 27% al 48%"*. Eso es una **predicción**, y una predicción se comprueba generando estrategias nuevas y viendo si se cumple.

Esta página compara varias generaciones del mismo activo — la aleatoria de referencia y las que hiciste después con distintas condiciones o distintos periodos — y responde a dos cosas:

1. **¿Entregó el filtro lo que prometía?** El umbral que salió de la muestra aleatoria se aplica a la muestra nueva y se compara lo predicho con lo observado, con su intervalo.
2. **¿Siguen mandando las mismas métricas?** Si la muestra nueva ordena los predictores igual que la de referencia, la conclusión aguanta; si los reordena, no era estable.

Cuándo lo usas, y cuándo no

Lo usas cuando tienes **generaciones independientes**: databanks con estrategias nuevas, creadas en corridas distintas de SQX, o la misma población medida en otro periodo.

No lo usas para comparar una población con un subconjunto suyo. Si `00S-sharpe` no son estrategias nuevas sino las 10.000 de siempre filtradas, no hay nada que replicar: sabes de antemano lo que va a salir, y el filtro del panel (página 1) ya te lo enseña. La comparación solo significa algo entre muestras que no comparten estrategias.

⚠ **Y no compares correlaciones entre muestras seleccionadas de forma distinta.** Si generaste `00S-sharpe` exigiendo Sharpe alto, dentro de esa muestra el Sharpe apenas varía, así que su correlación con cualquier resultado se desploma **por construcción**. Eso no significa que la conclusión fallara. El informe lo detecta y lo avisa, y por eso la comparación que manda es la del **resultado**, no la de la correlación.

Antes de empezar

Cada databank que quieras comparar necesita su exportación de métricas hecha (se lee de los `.sqx` en medio segundo, y la ventana la hace sola al elegir el databank):

```
python3 -m sqx.export.export_metrics --project XAUUSD --databank 00S-sharpe
```

El comando usa solo las métricas comunes a todas las muestras y te dice cuántas son.

Cómo se ejecuta

```
cd ~/Desktop/AlgoProject
python3 -m studies.screening.replication.report --project XAUUSD --reference 00S \
  --databank 00S-sharpe --databank 00S-rExpectancy --databank 00S-hasta2026
```

flag	obligatorio	qué hace
--project	sí	nombre del proyecto tal y como aparece en SQX
--reference	sí	el databank del que salieron las conclusiones. Normalmente la generación aleatoria
--databank	sí	databank a comprobar. Repetible : uno por cada muestra
--target	no	columna OOS a comparar. Repetible. Por defecto Sharpe Ratio (00S) y Ret/DD Ratio (00S)

Tarda unos **25 segundos** con tres muestras y dos objetivos. No toca SQX.

Qué produce

```
~/Desktop/AlgoData/reports/XAUUSD/_comparison/2026-09-04/replication/
  replication.md   la comparación (antes `comparison.md`, suelto en la carpeta del día)
  replication.html la misma comparación como página
  replication.json el resultado entero, en el contrato de estudios
  manifest.json   qué muestras, de qué fecha de exportación, con qué código
```

Va en `_comparison/` porque no pertenece a ningún databank: habla de varios a la vez. El guion bajo lo mantiene separado de las carpetas que sí son databanks.

Cómo se lee el resultado

Primera tabla: dónde acabó cada muestra

databank	strategies	median	hit %	Δ hit pp	95% CI on Δ	
00S	10,000	-0.280	25.6	-	-	
_selftest_half	5,000	-0.280	25.7	+0.1	[-1.4, +1.6]	
_selftest_sharpe	1,043	-0.030	45.8	+20.3	[+17.0, +23.3]	

Δ hit pp es la diferencia en tasa de acierto contra la referencia, y **el intervalo es lo que decide**: si incluye el 0, esa muestra no se distingue de la de referencia. Arriba, la primera no se distingue (era media población al azar) y la segunda sí (era el 10% de mejor Sharpe).

Segunda tabla: ¿entregó el filtro lo prometido?

filter	predicted hit %	% of sample passing	n	observed hit %
Δ 95% CI on Δ				
Sharpe Ratio (IS) top 5%	47.9	50.6	528	47.9
+0.0 [-6.1, +6.1]				
CAGR/Max DD % (IS) top 5%	47.7	47.8	499	47.3
-0.5 [-6.9, +5.5]				

columna	qué es
predicted hit %	lo que ese filtro consiguió en la muestra de referencia . Es la promesa
% of sample passing	cuánto de la muestra nueva pasa ese mismo umbral. Cerca de 100% significa que la muestra se generó para cumplirlo
observed hit %	lo que consiguen de verdad, en la muestra nueva, las que pasan el umbral
Δ y su intervalo	observado menos prometido. Si el intervalo incluye el 0, el filtro cumplió : no se desvía de lo que prometía

⚠ **Seis filas de acuerdo no son seis confirmaciones.** Los filtros de esta lista se solapan casi del todo (seleccionan prácticamente las mismas estrategias), así que se mueven juntos. Una muestra con suerte sube las seis a la vez. Mira el intervalo, no cuántas filas apuntan al mismo lado.

Tercera parte: ¿mandan las mismas métricas?

```
**_selftest_half** ranks the predictors like the reference at p +0.995.  
  
**_selftest_sharpe** ranks the predictors like the reference at p +0.407.  
Selected on 12 metric(s) – # of trades (IS), DoF Ratio (IS), Drawdown (IS), Max DD % (IS) –  
whose own correlations are attenuated here by construction.
```

Un p cercano a +1 significa que las dos muestras están de acuerdo en qué métricas predicen. Cuando baja, **mira primero la línea de debajo**: si la muestra fue seleccionada sobre esas métricas, la caída es aritmética y no dice nada. Si no lo fue, entonces sí: la conclusión no era estable.

Un ejemplo completo

Las salidas de arriba son de una **prueba del propio comando**, hecha el 2026-09-04 partiendo la exportación de XAUUSD/OOS en dos muestras artificiales para comprobar que detecta lo que debe:

- `_selftest_half` — media población al azar. **Debe salir "no hay diferencia"**, y sale: +0.1 pp con intervalo [-1.4, +1.6].
- `_selftest_sharpe` — el 10% de mejor Sharpe IS. **Debe replicar la predicción**, y sale: predicho 47.9%, observado 47.9%, Δ +0.0.

Con tus muestras de verdad el comando es el mismo, cambiando los nombres de los databanks. Las dos muestras de prueba se borraron después: no están en el data root.

Qué NO te dice

- **No dice por qué una muestra falló.** Dice que lo hizo. La causa —periodo distinto, plantilla distinta, otra configuración del generador— la sabes tú, y el informe no puede adivinarla.
- **No corrige por cuántas muestras compares.** Comparar diez muestras y quedarte con la que mejor salió es el mismo problema de siempre. Decide de antemano qué esperas de cada una.
- **No compara periodos distintos como si fueran el mismo experimento.** Una muestra "hasta 2026" difiere de la referencia en el periodo y en las estrategias; si sale distinta, no sabrás cuál de las dos cosas lo causó a menos que dejes una fija.
- **No mide dinero.** Tasa de acierto y mediana, con los números y las comisiones de SQX.

Si algo falla

lo que ves	qué pasa
<code>FileNotFoundError: .../metrics.csv</code>	ese databank no está exportado todavía
<code>0 in-sample metrics common to every sample</code>	alguna muestra es una exportación antigua hecha con otra vista. Vuelve a exportarla: ahora todas salen con las mismas columnas
una muestra con muy pocas estrategias	los intervalos se abrirán tanto que no dirán nada. Por debajo de ~200 no merece la pena compararla

4. Decaimiento — cuánto del edge sobrevive fuera de muestra, y si te la quedas o no

Qué pregunta responde

Generas estrategias sobre el histórico y luego las pruebas en un tramo que no vieron. Casi todas empeoran. Este análisis te dice, **estrategia por estrategia**, cuánto empeoró y si lo que le queda es un edge de verdad o el rastro de una racha con suerte. Termina con una sentencia por estrategia: **MANTENER**, **DUDOSA** o **DESCARTAR**.

La pregunta que hay detrás es la de Marcos López de Prado: una caída fuerte de rendimiento al salir de la muestra es el síntoma clásico del sobreajuste. Pero la caída sola engaña, y por eso aquí no se decide con ella. Se decide con tres cosas a la vez:

1. **¿El Sharpe fuera de muestra se distingue de cero?** Un Sharpe de 0,4 medido sobre cinco años tiene un error de $\pm 0,45$. Es decir: podría ser cero. La columna **t** es el Sharpe dividido por su propio error; por debajo de 1,65 no puedes afirmar que haya nada.
2. **¿Ganó todos los años, o solo alguno?** Con cinco años por delante, ganar tres es lo que sale tirando una moneda.
3. **¿De dónde sale el beneficio?** Si más de la mitad viene de un solo trimestre, no tienes una estrategia: tienes un billete de lotería premiado. La columna **concentración** por encima del 100% significa que fuera de ese trimestre la estrategia **pierde**.

Cuándo lo usas, y cuándo no

Úsalo cuando ya tienes un databank con estrategias que llevan resultado guardado en dos tramos — un IS y un OOS — y quieres saber con cuáles quedarte.

Cuándo NO sirve:

- Si el databank no tiene tramo fuera de muestra, no hay nada que comparar.
- Si ya filtraste ese mismo tramo OOS por rendimiento (por ejemplo "net profit > 0" sobre todo el OOS), el veredicto es **descriptivo, no predictivo**. Te dice lo que pasó, no lo que pasará: las estrategias que están ahí lo están precisamente porque ese tramo les salió bien. Para que fuera predictivo, el tramo con el que juzgas tendría que no haberse usado nunca para filtrar.
- No sirve para comparar plantillas entre sí sobre el papel. Agrupa por plantilla solo para que veas de dónde salen las supervivientes; no promedia nada, porque estrategias de plantillas distintas no son la misma población.

Antes de empezar

- El databank tiene que estar **volcado a disco**. SQX guarda las estrategias en memoria y solo escribe los **.sqx** al sincronizar; si la carpeta está vacía, abre SQX, entra en el databank y deja que sincronice.
- **No hace falta arrancar nada**. Este comando lee los **.sqx** directamente y no usa SQX ni el worker, así que puedes lanzarlo con la GUI abierta sin ningún riesgo.

Cómo se ejecuta

```
python3 -m studies.screening.decay.report --project XAUUSD --databank 00S \
--split 2018-01-01 --end 2022-12-31
```

flag	obligatorio	qué hace
--project	sí	nombre del proyecto tal y como aparece en SQX
--databank	sí	nombre del databank, con sus espacios si los tiene
--split	sí	primer día del tramo fuera de muestra. Todo lo anterior es IS
--end	sí	último día que se mira. Lo posterior se ignora

Tarda unos segundos para 834 estrategias. No toca SQX.

```
$ python3 -m tasks.reports.decay --project XAUUSD --databank 00S \
--split 2018-01-01 --end 2022-12-31

834 estrategias → /home/sergioguslw/Desktop/AlgoData/reports/XAUUSD/00S/2026-09-06
verdict
DUDOSA      522
DESCARTAR   308
MANTENER     4
```

Qué produce

En ~/Desktop/AlgoData/reports/<proyecto>/<databank>/<fecha>/decay/ (hasta el 25-09, sueltos en la carpeta del día):

archivo	qué es
verdict.csv	una fila por estrategia con todas las columnas, su identidad y su veredicto (antes decay.csv)
decay.html / decay.json	el mismo resumen como página y como resultado del contrato de estudios
decay.md	el resumen escrito: recuento, retención, desglose por plantilla y las que pasan todo
manifest.json	qué se analizó, con qué fechas y con qué versión del código

Los informes se acumulan por fecha: uno nuevo no borra el anterior.

Cómo se lee el resultado

Decaimiento — XAUUSD / OOS

834 estrategias · IS hasta 2018-01-01 · OOS 2018-01-01 → 2022-12-31 · informe 2026-09-06

Veredicto

veredicto	n
DUDOSA	522
DESCARTAR	308
MANTENER	4

Retención del Sharpe

Mediana 24% · p90 46% · máximo 110%

Ninguna estrategia con $t \geq 2$ (el máximo es 1.94): el Sharpe fuera de muestra no se distingue de cero en ninguna.

Por plantilla

plantilla	n	mantener	descartar
Strategy 1	128	0	62
Strategy 2	169	0	69
Strategy 3	74	0	36
Strategy 4	105	3	29
Strategy 5	166	0	59
Strategy 6	192	1	53

Las que pasan todo

estrategia	Sharpe IS	Sharpe OOS	retiene	t	años+	concentr.
Strategy 4.16.45	1.46	1.08	74%	1.94	5	16%
Strategy 4.18.51	1.38	1.02	74%	1.87	5	18%
Strategy 4.17.47	1.38	1.02	74%	1.87	5	17%
Strategy 6.18.78	1.34	0.91	68%	1.74	5	17%

Las columnas del CSV, de izquierda a derecha:

columna	qué es	qué valor es bueno
sharpe_is	Sharpe anualizado en el tramo de entrenamiento	contexto, no criterio
sharpe_oos	Sharpe anualizado fuera de muestra	cuanto más alto, mejor
retention	sharpe_oos / sharpe_is : la fracción del edge que sobrevivió	100% sería no perder nada; en la práctica la mediana ronda el 25%
t	sharpe_oos dividido por su error típico	la columna que manda. Por debajo de 1,65 no hay evidencia de edge
years_positive	años del tramo OOS que cerró en verde	4 o 5 de 5
worst_year	el peor año, en dinero	mide lo que tendrías que aguantar
concentration	qué parte del beneficio salió de su mejor trimestre	por debajo del 40%. Por encima del 100%, pierde el resto del tiempo
verdict	la sentencia	ver abajo

Las tres sentencias:

- **DESCARTAR** — el Sharpe fuera de muestra es negativo, o perdió en la mitad de los años, o más del 60% del beneficio viene de un solo trimestre. Cualquiera de las tres basta.
- **MANTENER** — $t \geq 1,65$, ganó en 4 de 5 años y ninguna concentración por encima del 40%.
- **DUDOSA** — todo lo demás. No es un aprobado flojo: es "los datos no dan para decidir". La mayoría cae aquí, y eso **es** el resultado, no un fallo del análisis.

Un ejemplo completo

Sobre el databank **005** de XAUUSD, 834 estrategias que ya habían pasado un filtro de net profit positivo fuera de muestra:

```
$ python3 -m studies.screening.decay.report --project XAUUSD --databank 005 \
--split 2018-01-01 --end 2022-12-31

834 estrategias → /home/sergioguslw/Desktop/AlgoData/reports/XAUUSD/005/2026-09-06
verdict
DUDOSA      522
DESCARTAR   308
MANTENER     4
```

Cómo se lee esto:

- **La retención mediana es del 24%.** De cada estrategia sobrevive una cuarta parte de su Sharpe. Eso no es una anomalía de unas pocas: es lo que le pasa a la población entera.
- **308 se descartan**, y el motivo dominante no es perder dinero — todas ganaban — sino la concentración: 283 sacan más del 60% de su beneficio de un solo trimestre, y 175 de ellas pierden dinero fuera de ese trimestre.
- **Ninguna llega a $t = 2$.** El máximo es 1,94. Traducido: ni una sola de las 834 tiene un rendimiento fuera de muestra que se distinga de la suerte con el criterio habitual del 5%.

- **Las 4 que pasan todo retienen entre el 68% y el 74% de su Sharpe**, ganan los cinco años y no concentran. Y 3 de las 4 salen de la misma plantilla.

Qué NO te dice

- **No te dice que las 4 supervivientes funcionen.** Dice que son las únicas que no puedes descartar con estos datos. Con 834 candidatas, que 4 destaquen es aproximadamente lo que produce el azar: si pruebas suficientes cosas, algunas salen bien solas. La confirmación tiene que venir de un tramo que estas estrategias no hayan visto nunca — un walk-forward hacia delante.
- **La retención por sí sola no clasifica.** Una estrategia que retiene el 90% de un edge que ya era ruido no vale más que una que retiene el 10% de uno bueno. Por eso la sentencia se apoya en `t`, en los años y en la concentración, y la retención se informa pero no decide.
- **No corrige por el número de intentos.** Si generaste 50 000 estrategias para quedarte con 834, el rendimiento de las mejores está inflado por esa búsqueda, y este informe no lo descuenta.
- **No mira las operaciones, mira la curva de equity diaria.** Un Sharpe calculado sobre P&L diario no es idéntico al que muestra SQX en el databank, que se calcula por operación. Las conclusiones no cambian, los decimales sí.

Si algo falla

- **StopIteration al leer un `.sqx`** — ese archivo no tiene curva de equity guardada, casi siempre porque la estrategia nunca llegó a ejecutarse en un backtest completo. Reconstrúyela en SQX o sácala del databank.
- **Salen 0 estrategias** — la carpeta del databank está vacía en disco. Es lo normal si SQX no ha sincronizado todavía: abre el databank en la GUI y espera a que escriba.
- **years_positive sale siempre 1** — te has equivocado con `--split` o `--end` y el tramo fuera de muestra cabe en un solo año natural.

29. La puerta OOS — de un databank entero a una lista de supervivientes

Qué pregunta responde

Has construido un montón de estrategias en un periodo y las has reteseado en el siguiente. Como SQX solo admite **un spread y un slippage por backtest**, y estas ventanas son de años sobre un activo que cambia mucho de precio, eso son dos tareas distintas y por tanto **dos databanks**: el de construcción y el de retesteo. Ahora tienes esos dos y no sabes qué estrategias merecen tu tiempo. La puerta las pasa por una **cascada de cribas**: primero las baratas, que tumban mucho; al final las caras, que solo ven a las que llegan vivas. Sale una lista de supervivientes, y para cada muerte, **en qué criba murió y con qué número**.

La puerta los **junta por estrategia** —por su identidad, no por su nombre— y los juzga juntos.

No es un filtro de métricas. Un filtro de métricas ya lo hace SQX con sus condiciones de aceptación. Esto añade lo que SQX no mira: cuánto se degradó respecto al periodo de construcción, si bate a un mono que operase el mismo mercado, y si tus 200 supervivientes son en realidad 30 repetidas.

Cuándo lo usas, y cuándo no

Lo usas cuando un proyecto propio ha terminado su tarea de build y su retest OOS, y quieres saber qué queda antes de gastar días de máquina en el protocolo de robustez.

No lo uses para juzgar al generador. Si la tarea de build llevaba condiciones de aceptación sobre el periodo OOS, esa población ya fue filtrada por la muestra que la puerta va a juzgar, y las cribas salen casi inertes. Se ve en el ejemplo de abajo: en `XAUUSD/005` sobreviven 228 de 231, y no porque sean buenas, sino porque solo entraron las que ya habían pasado ese corte. Para leer el resultado como un juicio hace falta un databank cuyo OOS **no** fuese condición de aceptación.

No decide nada por ti. Escribe el veredicto; borrar es otro comando (página 27).

Antes de empezar

- **Los dos databanks** tienen que existir en el mismo proyecto, con sus `.sqx` en disco.
- La cosecha lanza **un solo `orderstocsv`** en el conductor (worker de 5060) para sacar las operaciones de los dos lados; las métricas y las curvas se leen del `.sqx` sin SQX. Si otra sesión tiene el conductor, el comando se niega en vez de esperar.
- **Desde la ventana no hace falta lanzarla**: al elegir un databank de construcción, la cosecha se hace sola si falta o está vieja (capítulo 58, «La carga automática»).
- Si el proyecto vive en un worker en vez de en el maestro, pásale `--role custodian`.
- Las barras M1 del feed tienen que estar en la librería (`python3 -m sqx.export.syncBars --check`).

Cómo se emparejan las dos mitades

Por la **identidad** de la estrategia: el SHA-256 de su definición interna, que no cambia al reetestearla en otra ventana con otros costes (comprobado: 5 de 5 en un par real). **No por el nombre**, y esto no es teórico: Strategy 17.8.29 existe en dos databanks de este mismo proyecto y son estrategias completamente distintas, de plantillas distintas.

De ahí salen tres grupos, y los tres importan:

grupo	qué es	qué hace la puerta
emparejadas	están en los dos databanks	las juzga
sin OOS	están en el de build y no en el de retesteo	las descarta (criba presencia)
solo en OOS	están en el de retesteo y no en el de build	las ignora y las cuenta en el manifest

El grupo del medio es el importante: si SQX tiró una estrategia del retesteo porque saltó una de sus banderas rojas —demasiados trades ambiguos, o cualquier otra— esa decisión ya está tomada, y la estrategia se va. Y como el emparejamiento ocurre **antes** de exportar nada, no se gasta ni un segundo de máquina en ellas.

Cómo se ejecuta

Son **dos comandos**: uno saca los datos de SQX una sola vez, el otro juzga y se puede repetir tantas veces como quieras sin volver a tocar SQX.

```
python3 -m studies.screening.gate.harvest --project XAU_IS00S_ejemplo --databank Results --oos-databank OOS --role custodian
python3 -m studies.screening.gate.report --project XAU_IS00S_ejemplo --databank Results --feed XAUUSD_DukasM1_Infinox
```

--databank es siempre **el de construcción**, en los dos comandos: es el que da nombre a la carpeta de la cosecha, y el que define la población que entra.

studies.screening.gate.harvest — la cosecha

flag	obligatorio	qué hace
--project	sí	proyecto tal y como aparece en SQX
--databank	sí	el databank de construcción (IS), con sus espacios
--oos-databank	sí	el databank de retesteo (OOS)
--role	no	conductor o custodian si el proyecto vive en un worker; sin él, el maestro
--limit	no	una muestra aleatoria de N parejas , para una prueba

Toca SQX solo para las operaciones: copia los .sqx , lee sus métricas y curvas del propio fichero (las mismas columnas que la vista Export Data View , sin redondear) y lanza un único orderstocsv para los dos lados. 100 + 40 estrategias: **18 segundos** (antes, dos ciclos de arrancar y parar el conductor, unos minutos).

flag	obligatorio	qué hace
<code>--project</code> , <code>--databank</code>	sí	de qué cosecha lee (el databank de build); coge siempre la más reciente
<code>--feed</code>	sí	feed de SQX con el que se le pagan las barras al mono, p. ej. <code>XAUUSD_DukasM1_Infinox</code>
<code>--set</code>	no	cambia un umbral sin editar el fichero: <code>--set degradacion.min_t=1.65</code>

No toca SQX en absoluto. Sobre 231 estrategias tardó segundos: la cosecha se lee en 0,3 s y el mono cuesta 0,1 s por estrategia con 2.000 corridas nulas. Puedes reejecutarlo con otros umbrales todas las veces que quieras.

Dónde están los umbrales. Los números de las cribas no están en `config.yaml`: allí pone `ledger:gate.<criba>.<umbral>`, y el valor, con quién lo puso y cuándo, está en `ledger/thresholds.yaml`. Moverlo de verdad es editar esa fila; `--set` sólo prueba otro valor en una corrida.

Qué produce

La cosecha — `~/Desktop/AlgoData/harvest/<proyecto>/<databank de build>/<fecha>/`, fechada e inmutable. Todo va indexado por **identidad**, no por nombre:

fichero	qué es
<code>metrics.parquet</code>	una fila por estrategia y cada métrica dos veces : <code>[IS]</code> del databank de build y <code>[OOS]</code> del de retesteo. Más <code>strategy</code> y <code>strategy_build</code> , los dos nombres
<code>trades.parquet</code>	todos los trades de los dos lados, con una columna <code>sample</code> que dice de cuál viene cada uno
<code>equity.parquet</code>	la equity diaria de cada lado, igual con su <code>sample</code>
<code>missing_oos.csv</code>	las que están en el build y no en el retesteo: identidad y nombre
<code>manifest.json</code>	los dos databanks, la clave del join, y cuántas emparejaron

Los `.sqx` copiados y los CSV intermedios **se borran**: pesan diez veces más que el Parquet.

⚠ Si la cosecha imprime `AVISO: columnas (OOS) con datos`, ese databank **no** corrió una sola ventana: llevaba su propio corte IS/OOS dentro, y la puerta está tirando la mitad de sus números. Es el aviso de que le has dado un databank de otro tipo.

El juicio — `~/Desktop/AlgoData/reports/<proyecto>/<databank de build>/<fecha>/gate/`:

fichero	qué es
scorecard.parquet	una fila por estrategia y tres columnas por criba: el valor, si pasó y la nota
verdict.csv	para el databank de retesteo — la población que sigue adelante
verdict_build.csv	para el databank de construcción — el único que puede nombrar a las que SQX tiró del retesteo, porque allí no tienen nombre
funnel.csv	el embudo: por criba, cuántas entran, pasan y mueren
gate.md / gate.html / gate.json	el embudo con los umbrales que estaban puestos y por qué existe cada criba (hasta el 25-09, resumen.md); el .json es lo que pinta la ventana
estrategias/<nombre>.html / .json	la ficha de una estrategia: cada criba con su valor y su nota

Cómo se lee el resultado

Lo primero que se mira es el embudo que imprime por pantalla. Éste es un proyecto real con las dos tareas separadas — 120 estrategias construidas, 115 que llegaron al retesteo:

115 emparejadas + 5 sin 00S, ventana 2017-11-29 -> 2022-12-29

presencia	hard	entran	120	pasan	115	mueren	5
sanidad	hard	entran	115	pasan	112	mueren	3
estaticas	hard	entran	112	pasan	64	mueren	48
degradacion	hard	entran	64	pasan	45	mueren	19
forma	hard	entran	45	pasan	45	mueren	0
mono	hard	entran	45	pasan	45	mueren	0
familia	soft	entran	45	pasan	0	mueren	0
redundancia	soft	entran	45	pasan	45	mueren	0

45 de 120 sobreviven

Se lee de arriba abajo: **qué criba está haciendo el trabajo**. Aquí, dos:

criba	qué mató	qué dice
presencia	5	SQX las tiró del retesteo por sus propias banderas rojas. Comprobado: faltan también por nombre, no es un fallo de emparejamiento
sanidad	3	pocos trades o trades idénticos a otra
estaticas	48 de 112	el 43 % simplemente pierde dinero fuera de muestra, con el umbral más laxo que existe
degradacion	19	de las que ganan, casi un tercio no aguanta su propio error estándar
mono	0	con max_p: 0.50 . Pero la mediana de p entre los 45 supervivientes es 0,10 , y sólo 5 de 45 batirían al mono al 5 %

Y esos 45 supervivientes conservan una **mediana del 45 % de su Sharpe** de construcción, que es lo que se parece a la realidad. Compáralo con una población que ya venía filtrada por su propio OOS (XAUUSD/00S): allí el 99 % ganaba dinero, la retención mediana era **1,00** y el mono no mataba a nadie. Esos números no eran buenos, eran el filtro mirándose al espejo.

redundancia agrupa por la **estructura** de la estrategia — los bloques de su XML y su orden, ignorando los valores de los parámetros. Aquí los 45 supervivientes son **13 formas distintas, y una sola se lleva 24 de ellas**. No elimina a nadie, pero es lo que hay que saber antes de montar una cartera con "45 estrategias".

Una criba que mata 0 está puesta demasiado laxa o la población ya venía filtrada por eso mismo. Distinguir las dos cosas es mirar la distribución de su columna en el `scorecard.parquet`.

La columna `reason` del `verdict.csv` dice de qué murió cada descartada:

```
Strategy 21.30.45,DESCARTAR,...,presencia = 0 | SQX no la dejo en el databank 00S
Strategy 21.17.26,DESCARTAR,...,degradacion = 0.7249 | t=0.58 anos+=3 conc=1.06
Strategy 18.22.27,DESCARTAR,...,sanidad = 300 | trades identicos a otra estrategia
```

Las dos últimas son el caso que justifica la criba `sanidad`: **estrategias con los trades byte a byte idénticos** bajo nombres y hashes de fichero distintos. No son dos observaciones, son una.

Un ejemplo completo

```
$ python3 -m studies.screening.gate.harvest --project XAU_IS00S_ejemplo --databank Results \
--oos-databank 00S --role custodian
Results: 120 · 00S: 115 · emparejadas 115 (0 por nombre) · sin 00S 5 · solo en 00S 0
bloque con datos: build=(IS) · retesteo=(00S)
wrote /home/sergioguslw/Desktop/AlgoData/harvest/XAU_IS00S_ejemplo/Results/2026-09-23

$ python3 -m studies.screening.gate.report --project XAU_IS00S_ejemplo --databank Results \
--feed XAUUSD_DukasM1_Infinox
115 emparejadas + 5 sin 00S, ventana 2017-11-29 -> 2022-12-29
presencia      hard  entran   120 pasan   115 mueren    5
...
45 de 120 sobreviven -> .../reports/XAU_IS00S_ejemplo/Results/2026-09-23/gate
```

Probar un umbral más duro sin volver a tocar SQX:

```
$ python3 -m studies.screening.gate.report --project XAU_IS00S_ejemplo --databank Results \
--feed XAUUSD_DukasM1_Infinox --set mono.max_p=0.05 --set degradacion.min_t=1.65
```

Y aplicar el resultado dentro de SQX (página 27, con el install parado). Ojo con **cuál** de los dos veredictos aplicas a **cuál** databank:

```
$ python3 -m sqx.curate.apply_verdict --project XAU_IS00S_ejemplo --databank 00S --role
custodian \
    --verdict ~/Desktop/AlgoData/reports/XAU_IS00S_ejemplo/Results/2026-09-
23/gate/verdict.csv --apply
```

Qué NO te dice

- **No te dice que las supervivientes sean buenas.** Te dice que no murieron con los umbrales que tenías puestos. Hoy son deliberadamente laxos.
- **No deshace la preselección.** Si el build ya filtraba por OOS, la puerta mide ese filtro, no la estrategia. Lo avisa el `gate.md`, pero no lo puede arreglar.
- **No te dice por qué SQX tiró una estrategia del retesteo.** La criba `presencia` sabe que no está, no por qué. Eso está en el log del proyecto y en las banderas rojas de SQX.
- **No compara los costes de las dos tareas.** Cada mitad lleva el spread y el slippage que su tarea cobró, y eso es lo que quieres; pero si los pusiste mal en una de las dos, la degradación que mide la puerta es la de tus costes, no la del mercado.
- **El mono solo lee un escalón y un estadístico.** El escalón `timing` aleatoriza *cuándo* entra cada trade y nada más, y el estadístico por defecto es `sharpe`. Con `net` el mismo corpus da un resultado muy distinto (51 % contra 21,5 % de supervivientes, medido el 2026-09-22). El estadístico mueve el veredicto más que el nulo: página 26.
- **redundancia no dice que dos estrategias correlacionadas sean la misma.** Dice que a efectos de cartera aportan casi lo mismo durante ESE periodo.
- **Nada de esto sustituye al protocolo de robustez** (páginas 15, 17, 18, 19): la puerta elige a quién dedicarle esos días de máquina.

Si algo falla

- `KeyError: 'custodian'` — le has pasado un `--role` que no está en `config/machine.yaml`.
- `emparejadas 0` — los dos databanks no comparten ninguna estrategia. O te has equivocado de databank, o las del retesteo se regeneraron y ya no son las mismas: la identidad es la definición, y una estrategia reconstruida es otra estrategia.
- `KeyError: '00S'` al cargar la cosecha — esa cosecha es del formato viejo, de un solo databank. Vuelve a cosechar.
- El embudo dice `entran 0` en `estaticas` — la consulta de `keep` nombra una columna que esa vista no exporta. Mira las columnas reales en el `metrics.parquet` de la cosecha.
- `SystemExit` dentro del mono, hablando de `max_hold` — alguna estrategia mantiene una posición más barras de las que el escáner mira hacia delante. Es una negativa a propósito, no un fallo: subir `barrier.max_hold` en `engines/nulls/config.yaml` es la decisión que hay que tomar a mano.
- `REFUSING: another sqcli already holds SQX_w1` — otra sesión está usando el conductor. Espera a que acabe y repítelo (en la ventana, el botón  de la barra de carga).

49. SPA y StepM — ¿bate alguna al buy & hold, pagando toda la búsqueda?

Qué pregunta responde

La puerta OOS te dice qué estrategias pasan unas cribas. No te dice si alguna es **mejor que comprar el activo y quedarte quieto**, una vez descontado que has probado muchas. Con 115 estrategias, alguna va a batir al oro por pura suerte; la pregunta es si alguna lo bate **más de lo que la suerte explica**.

Lo contestan dos tests clásicos, uno detrás del otro:

- **SPA de Hansen** — *¿alguna de las K bate al buy & hold?* Da una p para la población entera.
- **StepM de Romano y Wolf** — *¿cuáles, en concreto?* Nombra estrategias, controlando la probabilidad de nombrar aunque sea una que no lo merece (el **FWER**, 0,05).

Cuándo lo usas, y cuándo no

Lo usas justo después de la puerta OOS (paso 8), sobre la misma cosecha. Va dentro de la skill `/oos-gate`, como paso 2b.

No corta nada. Decisión tuya del 2026-09-25: **anota y no elimina** hasta que veas cuánto cortaría. Su `verdict.csv` dice MANTENER para todas, así que pasárselo a `/curate` no mueve nada.

No sustituye al CSCV (paso 18). El CSCV mira las variantes de *una* madre y pregunta si tu forma de elegir parámetros sobreajusta. Esto mira K *estrategias distintas* y pregunta cuáles baten al benchmark. Son preguntas distintas.

Antes de empezar

Tienen que existir la cosecha y la puerta **sobre esa misma cosecha**:

1. `python3 -m studies.screening.gate.harvest ...` (paso 1 de `/oos-gate`)
2. `python3 -m studies.screening.gate.report ...` (paso 2)

Si la puerta más reciente juzgó otra cosecha, el comando se niega y te dice cuál. No toca SQX: se puede correr con todo abierto.

Cómo se ejecuta

```
python3 -m studies.screening.snoopingScreen.report --project XAU_IS00S_ejemplo --databank
Results \
    --feed XAUUSD_DukasM1_Infinox --symbol XAUUSD --timeframe M30 --family DirectionalMomentum
```

flag	obligatorio	qué hace
--project	sí	el proyecto, como en SQX
--databank	sí	el databank de construcción sobre el que corrió la puerta (Results)
--feed	sí	el feed de SQX: de ahí sale el precio del buy & hold
--symbol	sí	el fichero de activo: la ventana oos1 y el valor del punto
--timeframe	sí	sólo para el ledger: identifica el estudio
--family	sí	sólo para el ledger. Usa la misma familia que ya tenga el estudio (python3 -m ledger . report la lista), o la mirada se apunta en un estudio nuevo
--set	no	cambia un mando de config.yaml , p. ej. --set stepm.fwer=0.10

Tarda ~5 segundos con 115 estrategias. Salida real:

```

PROGRESS 5 115 estrategias contra el buy & hold
PROGRESS 100 0 de 115 baten al buy & hold

SPA lower 0.753 consistent 0.892 upper 0.901 (bloque medio 8 días)
StepM a FWER 0.05: 0 de 115 · Sharpe del buy & hold 0.405
ledger: XAUUSD_M30_DirectionalMomentum paso 8 ->
/home/sergioguslw/Desktop/AlgoData/reports/XAU_IS00S_ejemplo/Results/2026-09-25/snoopingScreen

```

⚠ Cada ejecución escribe una fila en el ledger, porque cada una es una mirada más al oos1 . Correrlo dos veces sobre lo mismo cuenta dos miradas.

Qué produce

En ~/Desktop/AlgoData/reports/<proyecto>/<databank>/<día>/snoopingScreen/ :

fichero	qué es
snoopingScreen.html / .md / .json	la población: las tres p, el histograma, las supervivientes de la puerta, lo que nombra el StepM
estrategias/<nombre>.html / .json	la ficha de cada estrategia
table.parquet	una fila por estrategia: Sharpe, exceso diario, lotes del buy & hold, si el StepM la nombra
verdict.csv	todas MANTENER, con la columna superior
manifest.json	qué cosecha juzgó y con qué mandos

Y una línea en ~/Desktop/AlgoData/ledger/<estudio>.jsonl , paso 8, sobre oos1 .

Cómo se lee el resultado

SPA y StepM contra el buy & hold — XAU_ISOOS_ejemplo / Results

[¿Bate alguna al buy & hold?](#)

0 de 115 baten al buy & hold

El StepM nombra 0 a un FWER de 0.05; sin descontar la búsqueda, 4 tienen un Sharpe mayor que el del buy & hold (0.405). SPA consistente: p = 0.892.

- SPA lower 0.753 cuenta a favor todas las candidatas malas: el suelo de la p
- SPA consistent 0.892 la de Hansen: descarta sólo las claramente peores que el benchmark
- SPA upper 0.901 cuenta en contra todas las candidatas malas: el test de White, el más conservador

¿Bate alguna al buy & hold?

Cosecha

/home/sergioguslw/Desktop/AlgoData/harvest/XAU_ISOOS_ejemplo/Results/2026-09-23 · tramo 2018-01-01 → 2023-01-01 · 1287 días · K = 115 estrategias emparejadas, no sólo las 45 que deja la puerta: la puerta eligió sobre este mismo tramo, y un test sobre lo que una elección dejó no puede cobrarse esa elección. Anota y no elimina (dueño, 2026-09-25).

Las tres p del SPA de Hansen

P	VALOR	QUÉ SUPONE
lower	0.753	cuenta a favor todas las candidatas malas: el suelo de la p
consistent	0.892	la de Hansen: descarta sólo las claramente peores que el benchmark
upper	0.901	cuenta en contra todas las candidatas malas: el test de White, el más conservador

Hipótesis nula: ninguna de las K bate al buy & hold a igual riesgo. La distancia entre lower y upper mide cuánto arrastran las candidatas malas.

Sharpe anual de las K, con el del buy & hold marcado

Las barras son las K estrategias; la línea, el buy & hold. Las que quedan a su derecha le ganan antes de descontar la búsqueda.

simuladas

banda

mediana 0.06545

buy & hold

Las supervivientes de la puerta

Arriba, el veredicto: cuántas nombra el StepM de las K. Aquí, 0 de 115.

Las tres p del SPA. Las tres responden a lo mismo —«ninguna bate al buy & hold»— y difieren en cómo tratan a las estrategias claramente peores que el oro:

p	qué supone	aquí
lower	todas las malas cuentan a favor: el suelo	0,753
consistent	la que se lee: descarta sólo las claramente peores	0,892
upper	todas en contra: la más conservadora	0,901

Una p pequeña (menor que 0,05) diría que *alguna* le gana al oro de verdad. 0,89 dice que lo que se ve se explica de sobra por haber probado 115.

El **histograma** es el Sharpe anual de las 115, con el del **buy & hold marcado con la línea** (0,405). Las barras a la derecha de la línea le ganan *antes* de descontar la búsqueda: aquí son 4, y las 4 están entre las 45 que deja la puerta.

La ficha de una estrategia:

SPA y StepM — Strategy 17.8.86

[Contra el buy & hold](#)

NO SUPERIOR

Su Sharpe supera al del buy & hold, pero entre 115 probadas eso lo da el azar: el StepM no la nombra.

- **Sharpe** 0.5441 buy & hold: 0.405
- **exceso diario** 6.63 USD por día sobre el buy & hold a igual riesgo
- **puerta OOS** la sobrevive

Contra el buy & hold

Contra el buy & hold

QUÉ	VALOR
Sharpe anual de la estrategia	0.5441
Sharpe anual del buy & hold	0.405
Lotes de buy & hold a igual riesgo	0.5006
Exceso medio diario (USD)	6.63

El buy & hold se dimensiona para que su P&L diario sea tan volátil como el de la estrategia; entonces un exceso positivo es exactamente un Sharpe mayor.

- **SUPERIOR** (verde): el StepM la nombra.
- **NO SUPERIOR** en ámbar: su Sharpe supera al del oro, pero con 115 probadas eso lo da el azar. Es el caso de **Strategy 17.8.86**: Sharpe 0,544 contra 0,405, y aun así no se puede nombrar.
- **NO SUPERIOR** en rojo: ni siquiera le gana al oro antes de corregir.

Lo que decide cada elección, dicho claro

¿Buy & hold de qué tamaño? A igual riesgo (lo elegiste el 2026-09-25): a cada estrategia se la compara con el oro comprado en la cantidad que hace que su P&L diario sea igual de volátil que el de ella. Así, un exceso positivo es **exactamente** un Sharpe mayor que el del oro. Con «la misma cantidad» o «todo el capital» el oro estaría dentro el 100 % del tiempo contra una estrategia que está dentro un 7 %, y entre 2018 y 2022 el test mediría cuánto subió el oro, no la estrategia. Es el mismo `equal_risk` del paso 21 (`10-cierre.pdf` > `38-exposicion`).

¿Por qué **K = 115** y no las **45 de la puerta**? Porque la puerta eligió mirando este mismo tramo. Si el test sólo viera las 45 que ganaron la elección, no podría cobrarse esa elección, y saldría optimista. Por eso prueba las 115 emparejadas y marca cuáles pasaron la puerta.

Lo que no puede ver. Lo que SQX probó y nunca guardó en el databank. Ese número lo lleva el ledger (`03-datos-costes-y-registro.pdf` > `43-ledger`), no este test.

Cómo sé que funciona

`python3 tests/test_snooping.py` fabrica datos cuya respuesta se conoce:

```
ok: sobre ruido el StepM nombra a alguien en 0 de 20 semillas (FWER 0.05); el edge plantado
sale
nombrado en 20 de 20; y a igual riesgo un exceso positivo es exactamente un Sharpe mayor que el
del
buy & hold
```

Sobre ese mismo ruido, un t-test ingenuo estrategia a estrategia «encuentra» algo en **15 de 20** semillas. Esa diferencia es lo que este test te ahorra.

Los mandos (`studies/screening/snoopingScreen/config.yaml`)

mando	valor	qué hace
<code>study.segment</code>	<code>oos1</code>	el tramo; el mismo que lee la puerta
<code>benchmark.sizing</code>	<code>equal_risk</code>	el buy & hold a igual riesgo
<code>stepm.fwer</code>	<code>0.05</code>	tu umbral; el número vive en <code>ledger/thresholds.yaml</code> (el <code>config.yaml</code> sólo dice <code>ledger:snoopingScreen.stepm.fwer</code>)
<code>bootstrap.reps</code>	<code>1000</code>	remuestreos del bootstrap
<code>bootstrap.seed</code>	<code>0</code>	fija: la misma cosecha nombra siempre las mismas